

אלגוריתם LZ77

אלגוריתמי דחיסה משמשים להקטנת הגודל של מידע לפני שמירתו או העברתו ברשת. המטרה היא לייצג את אותו מידע בצורה יעילה יותר, כך שניתן יהיה להשתמש בפחות מקום אחסון או להעביר פחות נתונים ברשת. קיימים מספר אלגוריתמים לדחיסת מידע, כאשר לכל אלגוריתם יש דרך שונה לזהות ולייצג מידע שחוזר על עצמו. אחד האלגוריתמים הבסיסיים והחשובים בתחום הוא LZ77.

מהו LZ77?

LZ77 הוא אלגוריתם דחיסה ללא איבוד מידע, כלומר Lossless Compression. משמעות הדבר היא שלאחר פתיחת הדחיסה ניתן לשחזר את המידע המקורי בדיוק, ללא שינוי או איבוד של נתונים. הרעיון המרכזי של LZ77 הוא לזהות רצפים של מידע שחוזרים על עצמם. במקום לשמור או להעביר את אותו רצף מספר פעמים, האלגוריתם יכול להפנות לרצף שכבר הופיע קודם. כך ניתן להחליף רצף ארוך בייצוג קצר יותר ולחסוך במקום.

הרעיון המרכזי של האלגוריתם

LZ77 עובר על המידע ומחפש רצפים שכבר הופיעו קודם לכן. כדי לעשות זאת, האלגוריתם משתמש באזור שנקרא Sliding Window. זהו אזור של מידע שכבר נקרא בעבר ומשמש את האלגוריתם כדי לחפש התאמות. כאשר האלגוריתם מגיע לרצף חדש, הוא בודק האם אותו רצף או חלק ממנו כבר מופיע בתוך ה Sliding Window. אם נמצאה התאמה, במקום לשמור שוב את כל התווים, ניתן לשמור מידע שמצביע על המקום שבו הרצף הקודם נמצא ועל האורך שלו. באופן זה, במקום להעביר את הרצף עצמו, מספיק להעביר הפניה אליו.

Sliding Window

ה Sliding Window הוא אחד החלקים המרכזיים באלגוריתם LZ77. אפשר לחשוב עליו כעל אזור זיכרון שמכיל כמות מוגבלת של המידע האחרון שהאלגוריתם כבר עבר עליו. החלון נע קדימה יחד עם התקדמות האלגוריתם במידע. מידע ישן יותר יוצא מהחלון, ומידע חדש שנקרא נכנס אליו.

המטרה של החלון היא לאפשר לאלגוריתם לחפש רצפים חוזרים במידע שכבר עבר עליו, בלי צורך לשמור את כל המידע מתחילתו. גודל החלון משפיע על יעילות הדחיסה. חלון גדול יותר מאפשר לחפש התאמות למרחק גדול יותר, אך דורש יותר זיכרון ועיבוד. כאשר האלגוריתם מוצא רצף שכבר הופיע קודם, הוא יכול לייצג אותו באמצעות שלושה ערכים עיקריים. הערך הראשון הוא Offset, שמציין כמה רחוק נמצאת ההתאמה מהמיקום הנוכחי. הערך השני הוא Length, שמציין כמה תווים יש ברצף שהתאים. הערך השלישי הוא התו הבא במידע, כאשר יש צורך בכך. לדוגמה, ניתן לחשוב על הפניה בצורה הבאה:

Offset = 5

Length = 4

Next Character = A

המשמעות היא שהאלגוריתם מצא רצף באורך ארבעה תווים שנמצא חמישה מקומות אחורה, ולאחר הרצף הזה מופיע התו A. במקום לשמור את ארבעת התווים עצמם, ניתן לשמור את ההפניה שמאפשרת לשחזר אותם.

תהליך הדחיסה

בתהליך הדחיסה האלגוריתם מתחיל לקרוא את המידע מההתחלה. בכל שלב הוא בודק את המידע הנוכחי מול המידע שכבר נמצא בתוך חלון החיפוש. אם לא נמצאה התאמה מתאימה, התו הנוכחי נשמר כחלק מהמידע הדחוס. אם נמצאה התאמה, האלגוריתם בודק מהו הרצף הארוך ביותר שניתן למצוא גם במידע הקודם וגם במידע הנוכחי. לאחר מכן הוא שומר הפניה הכוללת את המרחק להתאמה ואת אורך הרצף. האלגוריתם ממשיך לקרוא את המידע מהמקום שבו הסתיימה ההתאמה. כך התהליך ממשיך עד שכל המידע עבר עיבוד.

פתיחת הדחיסה

אחד היתרונות החשובים של LZ77 הוא שניתן לשחזר את המידע המקורי בדיוק. במהלך פתיחת הדחיסה, האלגוריתם קורא את המידע הדחוס ובודק האם מדובר בתו רגיל או בהפניה לרצף שכבר הופיע.

כאשר מתקבלת הפניה, האלגוריתם משתמש ב Offset כדי למצוא את המקום המתאים במידע שכבר שוחזר, ולאחר מכן מעתיק את מספר התווים שמוגדר באמצעות Length.
כך ניתן לבנות מחדש את המידע המקורי.
הפעולה מתבצעת לפי הסדר שבו המידע הדחוס נוצר, ולכן ניתן לשחזר את המידע גם כאשר יש הפניות לרצפים שהופיעו קודם לכן.

למה LZ77 חוסך מקום?

החיסכון נוצר מכיוון שרצפים שחוזרים על עצמם אינם חייבים להישמר מספר פעמים.
לדוגמה, אם קובץ מכיל את אותו רצף ארוך עשרות פעמים, שמירה של הרצף המלא בכל פעם יכולה לתפוס מקום רב.
LZ77 יכול לזהות שהרצף כבר הופיע ולשמור במקום זאת הפניה קצרה אליו.
היעילות של הדחיסה תלויה במידע עצמו. מידע שמכיל הרבה חזרות ורצפים דומים בדרך כלל מתאים יותר לדחיסה באמצעות LZ77. לעומת זאת, מידע אקראי או מידע שכבר עבר דחיסה יכול להיות קשה יותר לדחיסה.